实验五：EM 算法解决混合高斯模型聚类问题

一、问题描述

本实验考虑一个带隐变量的无监督聚类任务。给定一组二维观测数据，样本来自 K 个高斯分布的混合，但每个样本属于哪个高斯成分是未知的。目标是使用 EM 算法估计高斯混合模型（GMM）参数，并完成聚类。

根据题目要求，实验重点是手写 EM 过程，不直接调用现成的 GMM 聚类函数。最终输出聚类准确率（通过标签重排后与真实标签比较）以及对数似然曲线。

二、EM 算法原理

EM（Expectation-Maximization，期望最大化）算法是一类用于含有隐变量模型参数估计的迭代优化方法。其核心思想是：当观测数据不完整，或者模型中存在无法直接观测的隐变量时，原始似然函数往往难以直接求解，此时可以通过“先估计隐变量的分布，再更新模型参数”的方式，逐步逼近极大似然解。

在本实验中，EM 算法主要用于高斯混合模型（Gaussian Mixture Model, GMM）的参数估计。高斯混合模型假设样本数据并非来自单一高斯分布，而是由若干个高斯分布按照一定概率加权混合生成。因此，每个样本点属于哪一个高斯分量并不能直接观察到，这一“类别归属”就是模型中的隐变量，而 EM 算法正是求解该类问题的经典方法。

高斯混合模型的基本思想

设数据集为 $X = \{x_1, x_2, \ldots, x_N\}$, 其中每个样本 $x_i \in \mathbb{R}^d$。假设数据由 K 个高斯分布混合生成，则高斯混合模型可表示为

$$p(x_i \mid \Theta) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k),$$

其中：

π_k 表示第 k 个高斯分量的混合系数，满足 $\pi_k \geq 0, \quad \sum_{k=1}^{K} \pi_k = 1$, μ_k 表示第 k 个高斯分量的均值向量；Σ_k 表示第 k 个高斯分量的协方差矩阵；$\Theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^{K}$ 表示模型的全部参数。

其中，多元高斯分布的概率密度函数为

$$\mathcal{N}(x \mid \mu, \Sigma) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right).$$

从上述表达式可以看出，一个样本的概率密度是多个高斯分量加权求和后的结果。也就是说，我们只知道样本出现了，但并不知道它究竟由哪一个高斯分量生成，因此需要引入隐变量描述这一未知信息。

隐变量的引入

为了表示样本的类别归属，引入隐变量 $z_i = (z_{i1}, z_{i2}, \ldots, z_{iK})$,

其中 $z_{ik} \in \{0, 1\}$, $\sum_{k=1}^{K} z_{ik} = 1$. . 若 $z_{ik} = 1$，则表示样本 x_i 由第 k 个高斯分量生成；否则 $z_{ik} = 0$。显然，z_i 是一个 one-hot 编码向量。若隐变量 $Z = \{z_1, z_2, \ldots, z_N\}$ 已知，则完整数据的似然函数可以写为

$$p(X, Z \mid \Theta) = \prod_{i=1}^{N}\prod_{k=1}^{K}\left[\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)\right]^{z_{ik}}.$$

取对数可得完整数据对数似然函数

$$\log p(X, Z \mid \Theta) = \sum_{i=1}^{N}\sum_{k=1}^{K} z_{ik} \log\left[\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)\right].$$

如果隐变量 Z 已知，那么参数估计将变得非常直接，因为每个样本属于哪个分量已经明确给出。但在实际问题中，Z 是未知的，因此只能对其进行概率意义下的估计，这正是 EM 算法的出发点。

EM 算法的基本思想

EM 算法由两步交替进行：

- E 步（Expectation step）：在当前参数已知的条件下，计算隐变量的后验分布，即每个样本属于各个高斯分量的概率；
- M 步（Maximization step）：将 E 步得到的隐变量分布视为“软分配结果”，重新估计模型参数，使完整数据对数似然的期望最大化。

通过不断重复 E 步和 M 步，模型参数逐步更新，最终收敛到局部最优解。

E 步：计算后验概率（责任度）

在第 t 次迭代中，设当前参数为

$$\Theta^{(t)} = \{\pi_k^{(t)}, \mu_k^{(t)}, \Sigma_k^{(t)}\}_{k=1}^K.$$

E 步需要计算每个样本属于第 k 个高斯分量的后验概率，也称为“责任度”（responsibility）：

$$\gamma_{ik} = P(z_{ik} = 1 \mid x_i, \Theta^{(t)}).$$

根据贝叶斯公式可得

$$\gamma_{ik} = \frac{\pi_k^{(t)} \mathcal{N}(x_i \mid \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_{j=1}^K \pi_j^{(t)} \mathcal{N}(x_i \mid \mu_j^{(t)}, \Sigma_j^{(t)})}.$$

该值反映了样本 x_i 由第 k 个高斯分量生成的相对可能性，取值范围在 $[0, 1]$ 之间，且满足

$$\sum_{k=1}^K \gamma_{ik} = 1.$$

与 K-means 算法中“每个样本只属于某一个簇”的硬划分不同，GMM 中每个样本可以以不同概率同时属于多个簇，因此 EM 算法得到的是一种软聚类结果。也正因为这种软分配机制，高斯混合模型通常比 K-means 更灵活，能够描述不同大小、方向和形状的簇结构。

M 步：更新模型参数

在 E 步求得责任度 γ_{ik} 之后，M 步的目标是最大化完整数据对数似然的期望。定义

$$Q(\Theta, \Theta^{(t)}) = \mathbb{E}_{Z|X,\Theta^{(t)}}[\log p(X, Z \mid \Theta)].$$

将责任度代入后，可得

$$Q(\Theta, \Theta^{(t)}) = \sum_{i=1}^N \sum_{k=1}^K \gamma_{ik} \log \left[\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)\right].$$

对该目标函数分别关于 π_k, μ_k, Σ_k 求极值，可得到参数更新公式。首先定义第 k 个高斯分量的“有效样本数”：$N_k = \sum_{i=1}^N \gamma_{ik}$. 则混合系数更新为 $\pi_k^{(t+1)} = \frac{N_k}{N}$. 均值向量更

新为

$$\mu_k^{(t+1)} = \frac{1}{N_k} \sum_{i=1}^{N} \gamma_{ik} x_i.$$

协方差矩阵更新为

$$\Sigma_k^{(t+1)} = \frac{1}{N_k} \sum_{i=1}^{N} \gamma_{ik} (x_i - \mu_k^{(t+1)})(x_i - \mu_k^{(t+1)})^T.$$

从这些公式可以看出，EM 算法中的参数更新本质上是对每个高斯分量做加权统计：责任度越大的样本，对对应高斯分量参数的影响越大。

EM 算法的迭代过程

综合来看，EM 算法求解高斯混合模型参数的流程如下：

1. 初始化参数 $\Theta^{(0)} = \{\pi_k^{(0)}, \mu_k^{(0)}, \Sigma_k^{(0)}\}$；
2. 在当前参数下，计算每个样本对每个高斯分量的责任度 γ_{ik}；
3. 根据责任度计算各分量的有效样本数 N_k；
4. 更新混合系数、均值向量和协方差矩阵；
5. 计算新的对数似然值，判断是否收敛；
6. 若未收敛，则返回 E 步继续迭代。

其核心迭代结构可概括为：

初始化参数 $\to$ E 步：估计隐变量 $\to$ M 步：更新参数 $\to$ 判断收敛 $\to$ 重复迭代.

对数似然函数与收敛判据

在每次参数更新后，通常需要计算当前模型对观测数据的对数似然值：

$$\log p(X \mid \Theta) = \sum_{i=1}^{N} \log \left(\sum_{k=1}^{K} \pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k) \right).$$

EM 算法的重要性质之一是：在每一次迭代中，对数似然值不会下降，即

$$\log p(X \mid \Theta^{(t+1)}) \geq \log p(X \mid \Theta^{(t)}).$$

因此，EM 算法通常可通过以下方式判断是否收敛：

- 相邻两次迭代的对数似然增量小于给定阈值；
- 参数更新幅度小于给定阈值；
- 达到预设最大迭代次数。

在实验中，最常用的收敛判据是对数似然变化量是否足够小。

EM 算法的优点与局限性

EM 算法的优点主要体现在以下几个方面：

- 能够有效处理含有隐变量的概率模型；
- 每一步都有明确的数学意义，推导清晰；
- 对高斯混合模型参数估计尤其有效；
- 相较于硬聚类方法，能够提供更柔性的样本归属概率。

但 EM 算法也存在一定局限性：

- 对初始参数较为敏感，不同初始化可能导致不同结果；
- 只能保证收敛到局部最优解，不能保证全局最优；
- 当协方差矩阵接近奇异时，数值计算可能不稳定；
- 聚类数 K 通常需要事先指定。

因此，在实际应用中，常通过多次随机初始化、协方差正则化等方式提高算法稳定性。

三、实验步骤与实现细节

1. 生成二维三簇混合高斯模拟数据，并保留真实标签用于后续准确率评估；
2. 初始化参数：π_k 均匀、均值随机抽样、协方差初始化为样本协方差；
3. 执行 E 步，计算每个样本属于每个簇的责任度；

4. 执行 M 步，更新混合系数、均值和协方差矩阵；
5. 记录每次迭代的对数似然值，直到增量小于阈值或达到最大迭代次数；
6. 由责任度最大值给出聚类标签；
7. 由于聚类标签有置换不确定性，采用全排列匹配求最优准确率；
8. 绘制原始数据图、聚类结果图和对数似然曲线图。

四、核心代码

下面列出实现中最关键的 EM 主体结构。The code of this part is available at [1]

```python
class GMMEM:
    def __init__(self, n_components=3, max_iter=1000, tol=1e-6, random_state=7):
        self.n_components = n_components
        self.max_iter = max_iter
        self.tol = tol
        self.random_state = random_state
        self.pi_ = None
        self.means_ = None
        self.covs_ = None
        self.log_likelihood_history_ = []

    def _e_step(self, x):
        n_samples = x.shape[0]
        resp = np.zeros((n_samples, self.n_components))
        for k in range(self.n_components):
            resp[:, k] = self.pi_[k] * multivariate_gaussian_pdf(x, self.means_[k], self.covs_[k])
        row_sum = np.sum(resp, axis=1, keepdims=True)
        row_sum[row_sum == 0] = 1e-12
        resp = resp / row_sum
        return resp

    def _m_step(self, x, resp):
        n_samples, n_features = x.shape
```

[1] https://github.com/HaoranYuandomestic/ex5_EM_algorithm.git

```python
        nk = np.sum(resp, axis=0)
        nk[nk == 0] = 1e-12

        self.pi_ = nk / n_samples
        self.means_ = (resp.T @ x) / nk[:, np.newaxis]

        new_covs = np.zeros((self.n_components, n_features, n_features))
        for k in range(self.n_components):
            diff = x - self.means_[k]
            weighted_diff = resp[:, k][:, np.newaxis] * diff
            cov_k = (weighted_diff.T @ diff) / nk[k]
            cov_k += 1e-6 * np.eye(n_features)
            new_covs[k] = cov_k
        self.covs_ = new_covs

    def fit(self, x):
        self._initialize(x)
        prev_ll = None
        for _ in range(self.max_iter):
            resp = self._e_step(x)
            self._m_step(x, resp)
            ll = self._log_likelihood(x)
            self.log_likelihood_history_.append(ll)
            if prev_ll is not None and abs(ll - prev_ll) < self.tol:
                break
            prev_ll = ll
        return self
```

五、实验结果与分析

实验结果显示，对数似然曲线随迭代单调上升并最终趋于平稳，说明 EM 过程正常收敛。聚类结果图中，三个簇在平面上被较好地区分，估计均值基本落在各簇中心区域。

按题目要求，本实验输出了聚类准确率（采用最优标签映射后计算）。从结果看，准确率较高，说明手写 EM-GMM 能够较好恢复数据潜在分布结构。

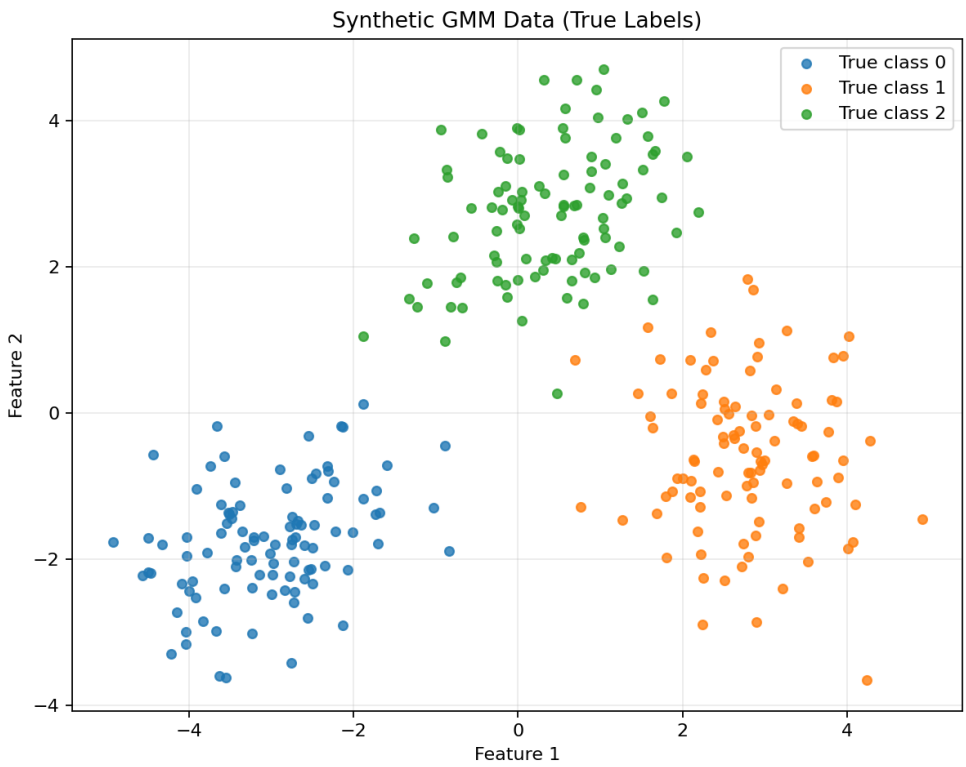

图 1: 混合高斯模拟数据（真实标签）

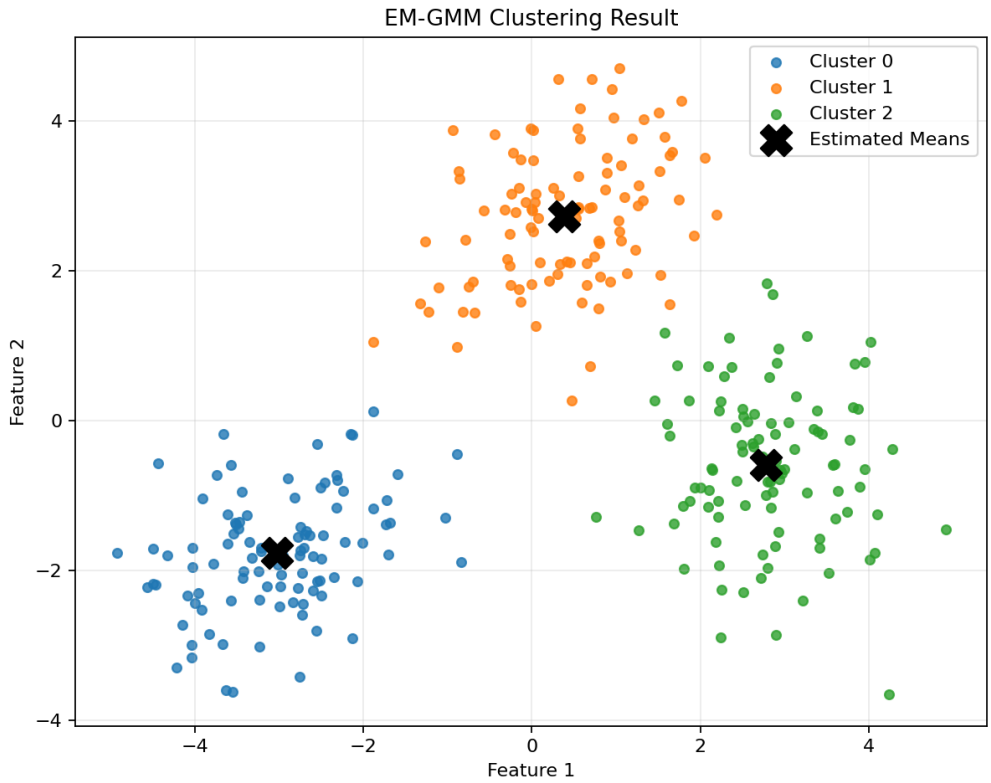

图 2: EM-GMM 聚类结果与估计均值

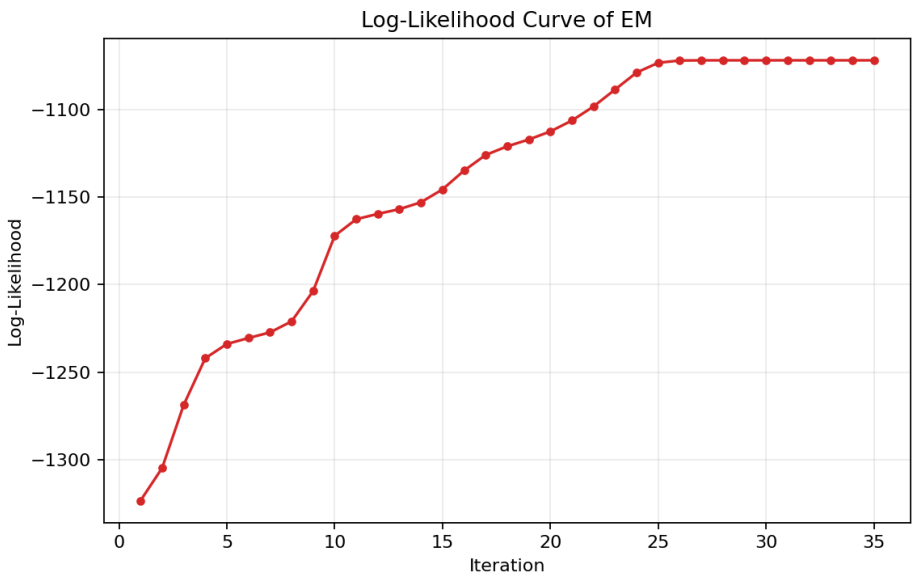

图 3: EM 迭代过程中的对数似然曲线

六、实验中遇到的问题与处理

1. 数值稳定性问题：协方差矩阵可能接近奇异，计算密度时容易不稳定。处理方法是在协方差对角线上加很小的正则项。

2. 下溢问题：直接连乘概率会非常小，容易造成数值下溢。实验中用对数似然作为收敛指标并在密度求和处做下界截断。

3. 标签无序问题：聚类标签编号与真实标签编号不一定一致，若直接比较会低估准确率。这里通过全排列匹配取最优映射后再计算准确率。

七、实验总结

本次实验从零实现了 EM 算法在 GMM 聚类中的完整流程，包括模型参数初始化、E 步与 M 步迭代、收敛判断和结果评估。实验结果表明，手写实现可以稳定收敛并得到较好的聚类效果。